

統計学+解析 II

1 ~ 20

No.

Date

①

$$\tilde{X} \in \mathbb{R}^{N \times P}, \tilde{y} \in \mathbb{R}^N, \beta \in \mathbb{R}^P$$

中身は元の式

$$\frac{\partial}{\partial \beta_j} \left\{ \sum_{i=1}^N \left(y_i - \sum_{k=1}^P \beta_k x_{ik} \right)^2 \right\} \quad (j=1, 2, \dots, N) \rightarrow \text{左辺}$$

$$= -2 \sum_{i=1}^N \left\{ \left(y_i - \sum_{k=1}^P \beta_k x_{ik} \right) x_{ij} \right\}$$

$$= -2 (x_{1j} \ x_{2j} \ \dots \ x_{Nj}) \begin{pmatrix} y_1 - \sum_{k=1}^P \beta_k x_{1k} \\ y_2 - \sum_{k=1}^P \beta_k x_{2k} \\ \vdots \\ y_N - \sum_{k=1}^P \beta_k x_{Nk} \end{pmatrix}$$

左辺

$$\begin{pmatrix} \frac{\partial}{\partial \beta_1} \sum_{i=1}^N \left(y_i - \sum_{k=1}^P \beta_k x_{ik} \right)^2 \\ \vdots \\ \frac{\partial}{\partial \beta_P} \sum_{i=1}^N \left(y_i - \sum_{k=1}^P \beta_k x_{ik} \right)^2 \end{pmatrix} = -2 \begin{pmatrix} x_{11} & \dots & x_{N1} \\ \vdots & & \vdots \\ x_{1P} & \dots & x_{NP} \end{pmatrix} \begin{pmatrix} y_1 - \sum_{k=1}^P \beta_k x_{1k} \\ \vdots \\ y_N - \sum_{k=1}^P \beta_k x_{Nk} \end{pmatrix}$$

□

$$\begin{pmatrix} \sum_{k=1}^p \beta_k x_{1k} \\ \vdots \\ \sum_{k=1}^p \beta_k x_{Nk} \end{pmatrix} = \begin{pmatrix} x_{11} & \cdots & x_{1p} \\ \vdots & & \vdots \\ x_{N1} & \cdots & x_{Np} \end{pmatrix} \begin{pmatrix} \beta_1 \\ \vdots \\ \beta_p \end{pmatrix} = \mathbf{x}\beta \quad \text{"表せた式"}$$

$$-2 \begin{pmatrix} x_{11} & \cdots & x_{N1} \\ \vdots & & \vdots \\ x_{1p} & \cdots & x_{Np} \end{pmatrix} \begin{pmatrix} y_1 - \sum_{k=1}^p \beta_k x_{1k} \\ \vdots \\ y_N - \sum_{k=1}^p \beta_k x_{Nk} \end{pmatrix}$$

$$= -2 \mathbf{x}^\top (\mathbf{y} - \mathbf{x}\beta)$$

□

目的関数 $L(\beta) = \|\mathbf{y} - \mathbf{x}\beta\|_2^2$ といた時に $L(\beta)$ は
 凸関数で "あるので" 徒々にして ① となる
 β が 最適解と言える。

$$\frac{\partial L}{\partial \beta} = -2 \mathbf{x}^\top (\mathbf{y} - \mathbf{x}\beta) = 0 \quad \text{の時}$$

$$\mathbf{x}^\top \mathbf{x}\beta = \mathbf{x}^\top \mathbf{y}$$

$$\hat{\beta} = (\mathbf{x}^\top \mathbf{x})^{-1} \mathbf{x}^\top \mathbf{y}$$

□

②

$$(a) f(x) = x$$

$$f(\alpha x + (1-\alpha)y) = \alpha x + (1-\alpha)y$$

$$\leq \alpha f(x) + (1-\alpha)f(y)$$

よって $f(x)$ は 凸 半微分 $Z = \partial f(0)$ について Z は任意の $x \in \mathbb{R}$ について以下を満たすような集合。

$$x \geq 0 + Z(x-0)$$

$$x \geq Zx \rightarrow \begin{cases} 1 \geq Z & x > 0 \\ 1 \leq Z & x < 0 \\ \text{不定} & x = 0 \end{cases}$$

従って $Z = \partial f(0) = [1]$ 四

$$(b) f(x) = |x|$$

$$f(\alpha x + (1-\alpha)y) = |\alpha x + (1-\alpha)y|$$

三角不等式

$$\leq |\alpha x| + |(1-\alpha)y|$$

$$\alpha \in (0, 1) \Rightarrow$$

$$= \alpha |x| + (1-\alpha)|y|$$

$$= \alpha f(x) + (1-\alpha)f(y) \text{ よって } \text{凸}$$

$$Z = \partial f(0) \text{ について}$$

$$|x| \geq Zx \rightarrow \begin{cases} 1 \geq Z & x > 0 \\ -1 \leq Z & x < 0 \\ \text{不定} & x = 0 \end{cases}$$

$$\text{従って } -1 \leq Z \leq 1$$

$$\text{よって } \partial f(0) = [-1, 1] \text{ 四}$$

(3)

(a) $g(x), h(x)$ が凸の時 $\beta, \gamma \geq 0$ を用いて

$$f(x) = \beta g(x) + \gamma h(x) \text{ とする. } \alpha \in (0, 1) \text{ について}$$

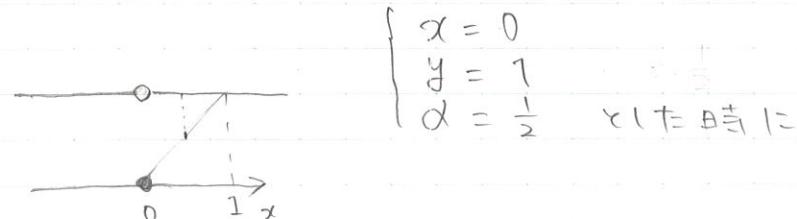
$$f(\alpha x + (1-\alpha)y) = \beta g(\alpha x + (1-\alpha)y) + \gamma h(\alpha x + (1-\alpha)y)$$

 $g(x), h(x)$ は凸関数, 定義より

$$\leq \beta f(\alpha g(x) + (1-\alpha)g(y)) + \gamma f(\alpha h(x) + (1-\alpha)h(y))$$

$$= \alpha \{ \beta g(x) + \gamma h(x) \} + (1-\alpha) \{ \beta g(y) + \gamma h(y) \}$$

$$= \alpha f(x) + (1-\alpha) f(y)$$

従って $\beta g(x) + \gamma h(x)$ は凸(b) $f(x) = \begin{cases} 1 & x \neq 0 \\ 0 & x = 0 \end{cases}$ が凸でないことを示す.

$$f(\alpha x + (1-\alpha)y) = f\left(\frac{1}{2}\right) = 1$$

 $-\frac{1}{2}$,

$$\alpha f(x) + (1-\alpha) f(y) = \frac{1}{2} \cdot 0 + \frac{1}{2} \cdot 1 = \frac{1}{2}$$

これは $f(\alpha x + (1-\alpha)y) \leq \alpha f(x) + (1-\alpha) f(y)$ を
満たさないから凸でない

$$\left\| \frac{1}{2} \begin{pmatrix} 1 \\ 0 \end{pmatrix} + \frac{1}{2} \begin{pmatrix} 0 \\ 1 \end{pmatrix} \right\|_0 = 1$$

$$\frac{1}{2} \left\| \begin{pmatrix} 0 \\ 1 \end{pmatrix} \right\|_0 + \frac{1}{2} \left\| \begin{pmatrix} 1 \\ 0 \end{pmatrix} \right\|_0 = 1$$

(C) (i) $f(\beta) = \frac{1}{2N} \|y - X\beta\|^2 + \lambda \|\beta\|_0$

$$g(\beta) = \|\beta\|_2^2$$

とすると

$$\forall \beta_1, \beta_2 \in \mathbb{R}^p, \forall \alpha \in (0, 1)$$

$$g(\alpha \beta_1 + (1-\alpha) \beta_2) - (\alpha g(\beta_1) + (1-\alpha) g(\beta_2))$$

$$= \alpha(1-\alpha) \left\{ \|\beta_1\|^2 - 2 \|\beta_1\| \|\beta_2\| + \|\beta_2\|^2 \right\}$$

$$= \alpha(1-\alpha) \|\beta_1 - \beta_2\|^2 \geq 0$$

よって $2\|\cdot\|$ は凸関数といふことになり
言え。

$$\beta_1 = \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \in \mathbb{R}^p \quad f(\alpha \beta_1 + (1-\alpha) \beta_2)$$

$$= f\left(\frac{1}{2} \mathbb{I}\right)$$

$$\beta_2 = \begin{pmatrix} 0 \\ 1 \\ \vdots \\ 1 \end{pmatrix} \in \mathbb{R}^p \quad = \frac{1}{2N} \|y - \frac{1}{2} \mathbb{I}\|^2 + \lambda p$$

$$\alpha = \frac{1}{2}$$

とすると

$$\text{また } \mathbb{I} = \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} \in \mathbb{R}^p$$

と表記する

$$\mathbb{I}^T \times^T \mathbb{I} = (\mathbb{B}_1 + \mathbb{B}_2)^T \times^T (\mathbb{B}_1 + \mathbb{B}_2) \geq \underbrace{\mathbb{B}_1^T \times^T \mathbb{B}_1}_{\text{半正定値}} + \mathbb{B}_2^T \times^T \mathbb{B}_2$$

$$\alpha f(\mathbb{B}_1) + (1-\alpha) f(\mathbb{B}_2) = \frac{\alpha}{2N} \|y - \mathbb{X}\mathbb{B}_1\|^2 + \frac{1-\alpha}{2N} \|y - \mathbb{X}\mathbb{B}_2\|^2 + \frac{\lambda P}{2}$$

$$= \frac{1}{2} \cdot \frac{1}{2N} \left(y^T y - 2y^T \times \mathbb{B}_1 + \mathbb{B}_1^T \times^T \mathbb{B}_1 + y^T y - 2y^T \times \mathbb{B}_2 + \mathbb{B}_2^T \times^T \mathbb{B}_2 \right) + \frac{\lambda P}{2}$$

$$= \frac{1}{2} \cdot \frac{1}{2N} \left(2y^T y - 2y^T \times (\mathbb{B}_1 + \mathbb{B}_2) + \mathbb{B}_1^T \times^T \mathbb{B}_1 + \mathbb{B}_2^T \times^T \mathbb{B}_2 \right) + \frac{\lambda P}{2}$$

$$= \frac{1}{2N} \left\{ y^T y - y^T \times (\mathbb{B}_1 + \mathbb{B}_2) + \frac{1}{2} (\mathbb{B}_1^T \times^T \mathbb{B}_1 + \mathbb{B}_2^T \times^T \mathbb{B}_2) \right\} + \frac{\lambda P}{2}$$

$$= \frac{1}{2N} \left\{ y^T y - y^T \times \mathbb{I} + \frac{1}{4} (\mathbb{B}_1^T \times^T \mathbb{B}_1 + \mathbb{B}_2^T \times^T \mathbb{B}_2) \right\} + \frac{\lambda P}{2}$$

$$+ \frac{1}{8N} (\mathbb{B}_1^T \times^T \mathbb{B}_1 + \mathbb{B}_2^T \times^T \mathbb{B}_2) - \frac{\lambda P}{2}$$

$$\frac{1}{8N} (\mathbb{B}_1^T \times^T \mathbb{B}_1 + \mathbb{B}_2^T \times^T \mathbb{B}_2) - \frac{\lambda P}{2} \leq 0$$

これがたまうに
入力選択Rまたは

$$\leq \frac{1}{2N} \|y - \frac{1}{2} \times \mathbb{I}\|_2^2 + \frac{\lambda P}{2}$$

$$= f(\alpha \mathbb{B}_1 + (1-\alpha) \mathbb{B}_2)$$

となるので"凸関数で"なくなる。

従って (i) は必ず"凸関数"になるとは
限りない。

$$(ii) f(\beta) = \frac{1}{2N} \|y - X\beta\|^2 + \lambda \|\beta\|_1,$$

ここで $g(\beta) = \|\beta\|_1$ とすれば

$$\forall x, y \in \mathbb{R}^p, \forall \alpha \in (0, 1)$$

$$g(\alpha x + (1-\alpha)y) = \|\alpha x + (1-\alpha)y\|_1,$$

$$\leq \|\alpha x\|_1 + \|(1-\alpha)y\|_1,$$

(\because ハムの不等式性質)

$$= \alpha \|x\|_1 + (1-\alpha)\|y\|_1,$$

$$= \alpha g(x) + (1-\alpha)g(y)$$

より $g(\beta)$ は凸関数, 前ページより第1項も凸関数

$f(\beta)$ は凸関数

$$(iii) f(\beta) = \frac{1}{N} \|y - X\beta\|^2 + \lambda \|\beta\|_2^2$$

前ページより2つ目は凸関数となるので

第1項, 第2項共に凸関数となり,

凸関数の和も凸関数

$f(\beta)$ は凸関数 四

(4)

(a) $f : \mathbb{R} \rightarrow \mathbb{R}$ 且し $x = x_0$ で 微分可能凸関数 $\alpha \in (0, 1)$ を用いて

$$f(\alpha x + (1-\alpha)x_0) \leq \alpha f(x) + (1-\alpha)f(x_0)$$

$$f(\alpha(x - x_0) + x_0) \leq \alpha \{f(x) - f(x_0)\} + f(x_0)$$

$$f(x_0 + \alpha(x - x_0)) - f(x_0) \leq \alpha \{f(x) - f(x_0)\}$$

 $\alpha > 0$ だけ

$$f(x) \geq f(x_0) + \frac{f(x_0 + \alpha(x - x_0))}{\alpha(x - x_0)}(x - x_0)$$

 $\alpha \rightarrow 0$ のとき $\alpha(x - x_0) \rightarrow 0$ だから

$$f(x) \geq f(x_0) + f'(x_0)(x - x_0) \quad \text{凸}$$

(ii) 半微分 " $Z = \partial f(x_0)$ と書くは"

$\forall x \in \mathbb{R}$

$$f(x) \geq f(x_0) + Z(x - x_0)$$

$$(*) \quad \begin{cases} \frac{f(x) - f(x_0)}{x - x_0} \geq Z & (x > x_0) \\ \frac{f(x) - f(x_0)}{x - x_0} \leq Z & (x < x_0) \end{cases}$$

任意の $x \in \mathbb{R}$ について (*) が成立する

$$\lim_{x \rightarrow x_0+0} \frac{f(x) - f(x_0)}{x - x_0} \leq Z \leq \lim_{x \rightarrow x_0-0} \frac{f(x) - f(x_0)}{x - x_0}$$

∴ f は x_0 で微分可能

$$\lim_{x \rightarrow x_0} \frac{f(x) - f(x_0)}{x - x_0} \text{ が存在する}$$

$$\lim_{x \rightarrow x_0+0} \frac{f(x) - f(x_0)}{x - x_0} = \lim_{x \rightarrow x_0-0} \frac{f(x) - f(x_0)}{x - x_0} = f'(x_0) \quad \text{かつさう}$$

$$Z = \{f'(x_0)\}$$

四

(5)

$$(a) f(x) = x^2 - 3x + |x|$$

$$= \begin{cases} x^2 - 3x + x & (x \geq 0) \\ x^2 - 3x - x & (x < 0) \end{cases}$$

$$f'(x) = \begin{cases} 2x - 2 & (x > 0) \\ 2x - 3 + [-1, 1] = [-4, -2] \neq 0 & (x = 0) \\ 2x - 4 & (x < 0) \end{cases}$$

∴ $x = 0$ で極小

$$(b) f(x) = x^2 + x + 2|x|$$

$$= \begin{cases} x^2 + x + 2x & (x \geq 0) \\ x^2 + x - 2x & (x < 0) \end{cases}$$

$$f'(x) = \begin{cases} 2x + 3 & (x > 0) \\ 1 + 2[-1, 1] = [-1, 2] \ni 0 & (x = 0) \\ 2x - 1 & (x < 0) \end{cases}$$

∴ $x = 0$ で極小

⑥

$$X \in \mathbb{R}^{N \times P} \quad y \in \mathbb{R}^N \quad \lambda \geq 0 \text{ とする},$$

$$= \frac{1}{N} X X^T = I \in \mathbb{R}^{N \times N}$$

$$L = \frac{1}{2N} \|y - X\beta\|_2^2 + \lambda \|\beta\|_1, \quad \alpha \text{ 半微分}.$$

$$s_j = \frac{1}{N} \sum_{i=1}^N x_{ij} y_i \text{ とする},$$

$$\frac{\partial L}{\partial \beta_j} = -\frac{1}{N} \left\{ \sum_{i=1}^N x_{ij} \left(y_i - \sum_{k=1}^P x_{ik} \beta_k \right) \right\} + \lambda \begin{cases} 1 & (\beta_j > 0) \\ [-1, 1] & (\beta_j = 0) \\ -1 & (\beta_j < 0) \end{cases}$$

$$\frac{\partial L}{\partial \beta_j} = -s_j + \beta_j + \begin{cases} \lambda & (\beta_j > 0) \\ [-\lambda, \lambda] & (\beta_j = 0) \\ -\lambda & (\beta_j < 0) \end{cases}$$

半微分が 0 のとき

$$0 \in \begin{cases} -s_j + \beta_j + \lambda & (\beta_j > 0) \\ -s_j + \beta_j + [-\lambda, \lambda] & (\beta_j = 0) \\ -s_j + \beta_j - \lambda & (\beta_j < 0) \end{cases}$$

(注記: β_j は正でなければならぬ)

$$\beta_j = \begin{cases} s_j - \lambda & (s_j > \lambda) \\ 0 & (-\lambda \leq s_j \leq \lambda) \\ s_j + \lambda & (s_j < -\lambda) \end{cases}$$

No.

Date

「17トキニ値関数

$$S_x(x) = \begin{cases} x - \lambda & x > \lambda \\ 0 & -\lambda \leq x \leq \lambda \\ x + \lambda & x < -\lambda \end{cases}$$

E用

$$\frac{\partial L}{\partial \beta_j} = 0 \quad \text{Eアリ=}\exists \beta_j \text{ は}$$

$$\beta_j = S_x(s_j) \quad \text{となる。}$$

⑦

$$S_\lambda(x) = \begin{cases} x - \lambda & x > \lambda \\ 0 & |x| \leq \lambda \\ x + \lambda & x < -\lambda \end{cases}$$

ε sign 関数, max 関数用いて表す.

$$f(x) = \text{sign}(x) (|x| - \lambda)_+ \quad (= \text{max})$$

(i) $x > 0$ のとき

$$f(x) = \max(x - \lambda, 0) \Leftrightarrow \begin{cases} x - \lambda & (x > \lambda) \\ 0 & (0 < x \leq \lambda) \end{cases}$$

(ii) $x = 0$ のとき

$$f(x) = 0$$

(iii) $x < 0$ のとき

$$f(x) = -\max(-x - \lambda, 0) \Leftrightarrow \begin{cases} x + \lambda & (x < -\lambda) \\ 0 & (-\lambda \leq x < 0) \end{cases}$$

以上より

$$f(x) = \begin{cases} x - \lambda & (x > \lambda) \\ 0 & (-\lambda \leq x \leq \lambda) \\ x + \lambda & (x < -\lambda) \end{cases}$$

となるので $f(x) = S_\lambda(x)$ となる

四

(10)

 $\lambda \beta^H + \text{正則化項}$

$$L(\beta) = \frac{1}{2N} \|y - X\beta\|_2^2 + \lambda \|\beta\|,$$

∴ 最適解は $\beta = 0$ となる。

ただし、行列の直交性が仮定できない時。

$$\partial L / \partial \beta_j = -\frac{1}{N} \sum_{i=1}^N x_{ij} \left(y_i - \underbrace{\sum_{k=1}^P x_{ik} \beta_k}_{r_{ij}} \right) + \lambda \begin{cases} 1 & (\beta_j > 0) \\ [-1, 1] & (\beta_j = 0) \\ -1 & (\beta_j < 0) \end{cases}$$

$$\frac{y_i - \sum_{k \neq j}^P x_{ik} \beta_k}{\|x_{ij}\|} - x_{ij} \beta_j$$

r_{ij} とする。

$$\frac{\partial L}{\partial \beta_j} = -\frac{1}{N} \sum_{i=1}^N x_{ij} (r_{ij} - x_{ij} \beta_j) + \lambda \begin{cases} 1 \\ [-1, 1] \\ -1 \end{cases}$$

 $\beta_k (k \neq j)$ を固定して r_{ij} を計算できる。 β_j を更新する

→ 座標降下法

$$\beta_j = \frac{\sum_i \left(\frac{1}{N} \sum_{i=1}^N x_{ij} r_{ij} \right)}{\frac{1}{N} \sum_{i=1}^N (x_{ij})^2}$$

j = 1, 2, ..., P について
更新を繰り返す

今日簡単。ため

$$\sum_{i=1}^N (x_{ij})^2 = 1$$

+ 大きな 入力に対しては、 $\beta = 0$ も最直解であり。

$$-\lambda \leq -\frac{1}{N} \sum_{i=1}^N x_{ij} (r_{ij} - x_{ij} \beta_j) \leq \lambda$$

が成立する

よって

$$r_{ij} = y_i - \sum_{k \neq j}^P x_{ik} \beta_k = y_i \quad (i=1, 2, \dots, N)$$

入力を徐々に小さくしていくと

$$-\frac{1}{N} \left| \sum_{i=1}^N x_{ij} y_i \right| \leq \lambda \quad (j=1, \dots, P)$$

について等式が成立する
jが存在することになる。

このときの j は

$$-\frac{1}{N} \left| \sum_{i=1}^N x_{ij} y_i \right| = \lambda$$

このうちの j は

$$j = \underset{j=1, 2, \dots, P}{\operatorname{argmin}} \frac{1}{N} \left| \sum_{i=1}^N x_{ij} y_i \right| \text{ で} " \text{最小} \text{ 値} \text{ の} \text{ とき}"$$

入の最小値は

$$\lambda = \max_{1 \leq j \leq P} \left| \frac{1}{N} \sum_{i=1}^N x_{ij} y_i \right| \quad \boxed{\text{四}}$$

(17)

$\mathbf{X}^\top \mathbf{X}$ は $\forall \mathbf{x} \in \mathbb{R}^P$ を用いて

$$\mathbf{x}^\top \mathbf{X}^\top \mathbf{X} \mathbf{x} = \|\mathbf{X} \mathbf{x}\|_2^2 \geq 0 \text{ より}$$

$\mathbf{X}^\top \mathbf{X}$ は半正定値行列なので

$\gamma_1, \dots, \gamma_P \geq 0$ が成立つ。

$\gamma_1 = 0$ とすれば \mathbf{x}_1 は固有値より固有方程式の解の一つである
よって

$$\phi_{\mathbf{X}^\top \mathbf{X}} = \det(0I - \mathbf{X}^\top \mathbf{X}) = 0$$

$$\det(\mathbf{X}^\top \mathbf{X}) = 0 \quad \text{よって } \mathbf{X}^\top \mathbf{X} \text{ は正則でない}$$

$\mathbf{X}^\top \mathbf{X}$ に逆行列がない

存在しない

従って上の条件は

$$\gamma_i \quad (i=1, \dots, P) \quad \text{かつ } \gamma_i < 0 \text{ もしくは } 0 \text{ のとき}$$

$\mathbf{X}^T \mathbf{X}$ の固有値は 固有方程式

$$\phi(\gamma) = \det (\gamma I - \mathbf{X}^T \mathbf{X}) = 0$$

の解であり、これを
 $\gamma_1, \gamma_2, \dots, \gamma_p$ と表す。

ここで $\mathbf{X}^T \mathbf{X} + N\lambda I$ についての 固有方程式は、

$$\begin{aligned}\phi(\tau) &= \det (\tau I - \mathbf{X}^T \mathbf{X} - N\lambda I) \\ &= \det ((\tau - N\lambda)I - \mathbf{X}^T \mathbf{X})\end{aligned}$$

よって

$\mathbf{X}^T \mathbf{X} + N\lambda I$ の 固有値 $\tau_1, \tau_2, \dots, \tau_p$ は

$$\tau_i - N\lambda = \gamma_i \quad (i=1, 2, \dots, p)$$

$$\underline{\tau_i = \gamma_i + N\lambda \quad (i=1, 2, \dots, p)}$$

となる。

以上より $\lambda > 0$ と $\gamma_i \geq 0$ ($i=1, 2, \dots, p$) であるので

$$\tau_i > 0 \quad (i=1, 2, \dots, p)$$

となり全ての 固有値が 正なので

$\mathbf{X}^T \mathbf{X} + N\lambda I$ には必ず 逆行列が
存在する。

(12)

 $\lambda \geq 0$

$$\underset{\beta}{\operatorname{argmin}} \quad \frac{1}{2N} \|y - X\beta\|_2^2 + \frac{\lambda}{2} \|\beta\|_2^2$$

 $L(\beta)$ β で微分して

$$\frac{\partial L}{\partial \beta} = -\frac{1}{N} X^T (y - X\beta) + \lambda \beta$$

 $L(\beta)$ は凸関数より微分して ① の点を求めて

$$\frac{\partial L}{\partial \beta} = 0$$

$$(X^T X + N\lambda I) \hat{\beta} = X^T y$$

前提より

必ず逆行列が存在する $\alpha \in \mathbb{R}$

$$\hat{\beta} = (X^T X + N\lambda I)^{-1} X^T y$$

四

(15)

$$(i) S(\beta) = \sum_{i=1}^N (y_i - \beta_1 x_{i1} - \beta_2 x_{i2})^2$$

$$y \in \mathbb{R}^N$$

$$X = \begin{pmatrix} x_{11} & x_{12} \\ \vdots & \vdots \\ x_{N1} & x_{N2} \end{pmatrix} \in \mathbb{R}^{N \times 2}$$

$$\beta = \begin{pmatrix} \beta_1 \\ \beta_2 \end{pmatrix} \in \mathbb{R}^2$$

$$S(\beta) = \|y - X\beta\|^2$$

Sは凸関数

偏微分して 0 となる点を求める

$$\frac{\partial S}{\partial \beta} = (-2X^\top)(y - X\beta) = 0$$

$$\hat{\beta} = (X^\top X)^{-1} X^\top y$$

$$\hat{y} = X\hat{\beta} = X(X^\top X)^{-1} X^\top y$$

$$\begin{aligned} \left| \begin{array}{c} \sum_{i=1}^N x_{i1}(y_i - \hat{y}_i) \\ \sum_{i=1}^N x_{i2}(y_i - \hat{y}_i) \end{array} \right| &= X^\top (y - \hat{y}) = X^\top y - \underbrace{X^\top X}_{\text{正則}} (X^\top X)^{-1} X^\top y \\ &= X^\top y - X^\top y \\ &= 0 \end{aligned}$$

よって (i) は成り立つ。

(ii)

$$\forall \beta \in \mathbb{R}^2 \quad i=1, 2, \dots, n$$

$$\hat{y}_i = \mathbf{x}_i^\top \hat{\beta}$$

と用ひる

$$y_i - \mathbf{x}_i^\top \beta = y_i - \mathbf{x}_i^\top \beta - (\hat{y}_i - \mathbf{x}_i^\top \hat{\beta}) + (\hat{y}_i - \mathbf{x}_i^\top \hat{\beta})$$

$$= (y_i - \hat{y}_i) - \mathbf{x}_i^\top (\beta - \hat{\beta}) \quad \cdots (*)$$

とする各要素 i ($i=1, 2, \dots, N$) $i=1, 2, \dots, n$

$$y_i - \beta_1 x_{i1} - \beta_2 x_{i2} = y_i - \hat{y}_i - (\beta_1 - \hat{\beta}_1) x_{i1} - (\beta_2 - \hat{\beta}_2) x_{i2}$$

とする (ii) が成り立つ。

(*) の 2 つを考えて

$$\|y - \mathbf{x}^\top \beta\|_2^2 = \|(y - \hat{y}) - \mathbf{x}^\top (\beta - \hat{\beta})\|_2^2$$

$$= \|y - \hat{y}\|^2 - \underbrace{2(\beta - \hat{\beta})^\top \mathbf{x}^\top (y - \hat{y})}_{\text{0}} + \|\mathbf{x}^\top (\beta - \hat{\beta})\|^2$$

$$= \|y - \hat{y}\|^2 + \underbrace{(\beta - \hat{\beta})^\top \mathbf{x}^\top \mathbf{x}^\top (\beta - \hat{\beta})}_{\text{2 次形式}}$$

$$= (\beta_1 - \hat{\beta}_1)^2 \sum_{i=1}^N x_{i1}^2 + 2(\beta_1 - \hat{\beta}_1)(\beta_2 - \hat{\beta}_2) \sum_{i=1}^N x_{i1} x_{i2}$$

$$+ (\beta_2 - \hat{\beta}_2)^2 \sum_{i=1}^N x_{i2}^2 + \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

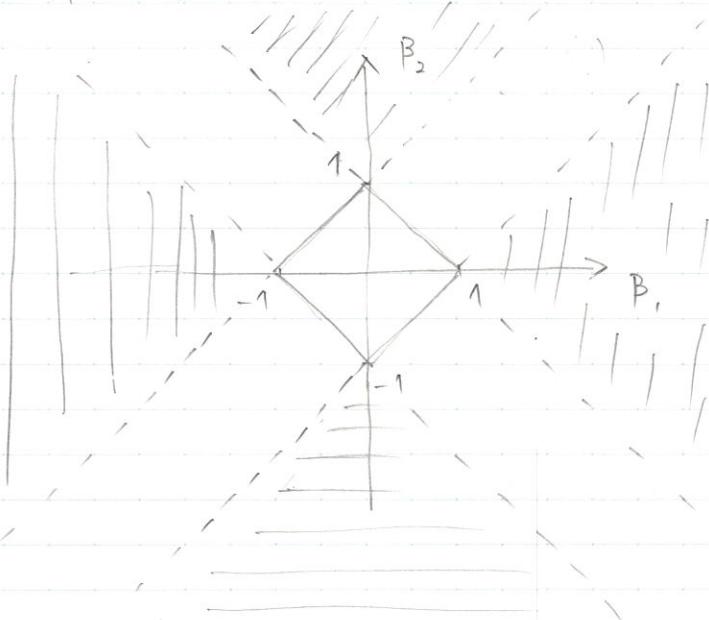
が成り立つ 四

$$(h) \sum_{i=1}^N x_{i1}^2 = \sum_{i=1}^N x_{i2}^2 = 1, \quad \sum_{i=1}^N x_{i1} x_{i2} = 0 \quad \text{の場合を考える。}$$

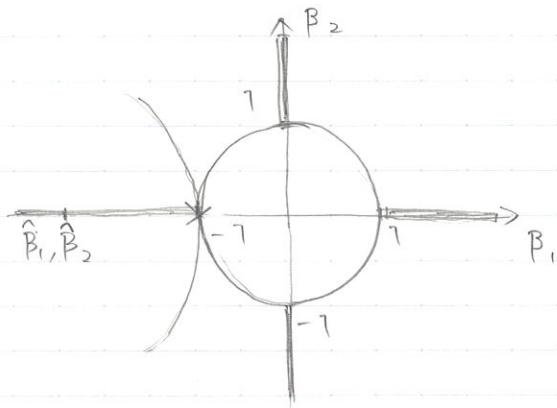
目的関数

$$\begin{aligned} L(\beta) &= \|y - X\beta\|^2 \\ &= (\beta_1 - \hat{\beta}_1)^2 + (\beta_2 - \hat{\beta}_2)^2 + \sum_{i=1}^N (y_i - \hat{y}_i)^2 \end{aligned}$$

制約 $|\beta_1| + |\beta_2| \leq \text{const}$



(c) 制約式の場合



式の \hat{P}_1, \hat{P}_2 は P_1, P_2 軸上かつ単位円外
に在る。

(16)

$$L = \frac{1}{N} \sum_{i=1}^N (y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j)^2 + \lambda \sum_{j=1}^p \beta_j^2$$

$$\frac{\partial L}{\partial \beta_k} = -\frac{2}{N} \sum_{i=1}^N x_{ik} (y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j)^2 + 2\lambda \beta_k = 0$$

$$\frac{1}{N} \sum_{i=1}^N x_{ik} (y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j)^2 - \lambda \beta_k = 0$$

同様に

$$\frac{\partial L}{\partial \beta_l} = 0$$

$$\frac{1}{N} \sum_{i=1}^N x_{il} (y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j)^2 - \lambda \beta_l = 0$$

 $\Rightarrow x_{il} = x_{ik}$ のとき.

$$\beta_k = \frac{1}{N} \sum_{i=1}^N x_{ik} (y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j)^2$$

$$= \frac{1}{N} \sum_{i=1}^N x_{il} (y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j)^2 = \beta_l$$

VII

$$X = \begin{bmatrix} 1 & \dots & 1 \\ \vdots & \ddots & \vdots \\ 1 & \dots & 1 \end{bmatrix}_N$$

(8) elastic net

$$L(\beta) = \frac{1}{2N} \|y - \beta_0 - X\beta\|^2 + \lambda \left\{ \frac{1-\alpha}{2} \|\beta\|_2^2 + \alpha \|\beta\|_1 \right\}$$

X, y_0 中心化で $\beta_0 = 0$ とする。

$$\frac{\partial L}{\partial \beta} = -\frac{1}{N} X^T (y - X\beta) + \lambda(1-\alpha)\beta + \lambda\alpha \frac{\partial}{\partial \beta} \|\beta\|_1$$

j番目要素 $= \frac{1}{N} \sum_{i=1}^N x_{ij} (y_i - \sum_{k \neq j} x_{ik} \beta_k)$

$$0 \in -\frac{1}{N} \underbrace{[X^T(y - X\beta)]_j}_{\downarrow} + \lambda(1-\alpha)\beta_j + \lambda\alpha \begin{cases} 1 & \beta_j > 0 \\ [-1, 1] & \beta_j = 0 \\ -1 & \beta_j < 0 \end{cases}$$

$$\begin{aligned} & \sum_{i=1}^N x_{ij} \left(y_i - \sum_{k \neq j}^P x_{ik} \beta_k - x_{jj} \beta_j \right) \\ &= \sum_{i=1}^N x_{ij} (r_{ij} - x_{jj} \beta_j) \end{aligned}$$

$$0 \in -\frac{1}{N} \sum_{i=1}^N x_{ij} r_{ij} + \left\{ \frac{1}{N} \sum_{i=1}^N x_{jj}^2 + \lambda(1-\alpha) \right\} \beta_j + \lambda\alpha \begin{cases} 1 & \beta_j > 0 \\ [-1, 1] & \beta_j = 0 \\ -1 & \beta_j < 0 \end{cases}$$

ここで「 t_j が β_j の値関数の定義より」

$$0 \in -s_j + t_j \beta_j + \mu \begin{cases} 1 & \beta_j > 0 \\ [-1, 1] & \beta_j = 0 \\ -1 & \beta_j < 0 \end{cases}$$

(i) $\beta_j > 0$ の時.

$$-s_j + t_j \beta_j + \mu = 0$$

$$t_j \beta_j = s_j - \mu \quad (s_j > \mu)$$

(ii) $\beta_j = 0$ の時

$$-s_j + \mu[-1, 1] \ni 0$$

$$-\mu \leq s_j \leq \mu$$

(iii) $\beta_j < 0$ の時

$$-s_j + t_j \beta_j - \mu = 0$$

$$t_j \beta_j = s_j + \mu \quad (s_j < -\mu)$$

$$t_j \beta_j = S_\mu(s_j)$$

$$\text{ここで「前へ - シテ」} \quad s_j = \frac{1}{N} \sum_{i=1}^N x_{ij} r_{ij}, \quad t_j = \frac{1}{N} \sum_{i=1}^N x_{ij}^2 + \lambda(1-\alpha)$$

$$t_j \beta_j = S_\mu(s_j)$$

$$\mu = \lambda \alpha \text{ とすれば}$$

$$\left\{ \frac{1}{N} \sum_{i=1}^N x_{ij}^2 + \lambda(1-\alpha) \right\} \beta_j = S_{\lambda \alpha} \left(\frac{1}{N} \sum_{i=1}^N x_{ij} r_{ij} \right)$$


```
In [1]: import copy
import japanize_matplotlib
%matplotlib inline
import matplotlib.pyplot as plt
import numpy as np
import scipy
from matplotlib.pyplot import imshow
from numpy.random import randn
from scipy import stats
import matplotlib.pyplot as plt
```

問題 1

```
In [2]: def linear(X, y):
    p = X.shape[1]
    x_bar = np.zeros(p)
    for j in range(p):
        x_bar[j] = np.mean(X[:, j])
    for j in range(p):
        X[:, j] = X[:, j] - x_bar[j]    # Xの中心化
    y_bar = np.mean(y)
    y = y - y_bar                  # yの中心化
    beta = np.dot(                  #(1)
        np.linalg.inv(np.dot(X.T, X)),
        np.dot(X.T, y)
    )
    beta_0 = y_bar - np.dot(x_bar, beta)    #(2)
    return beta, beta_0
```

問題5

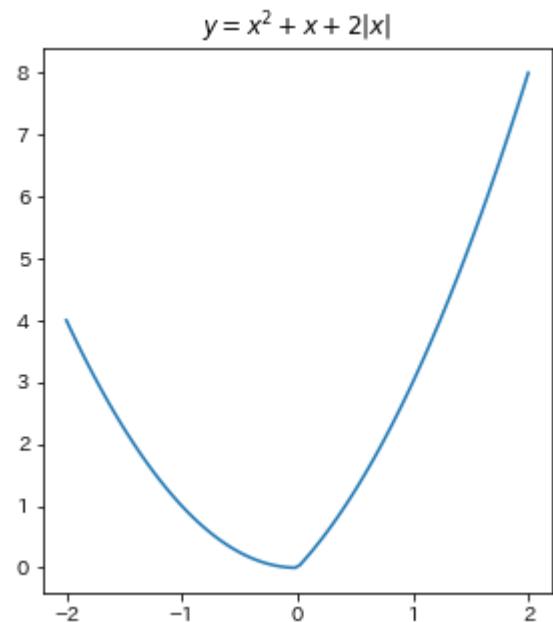
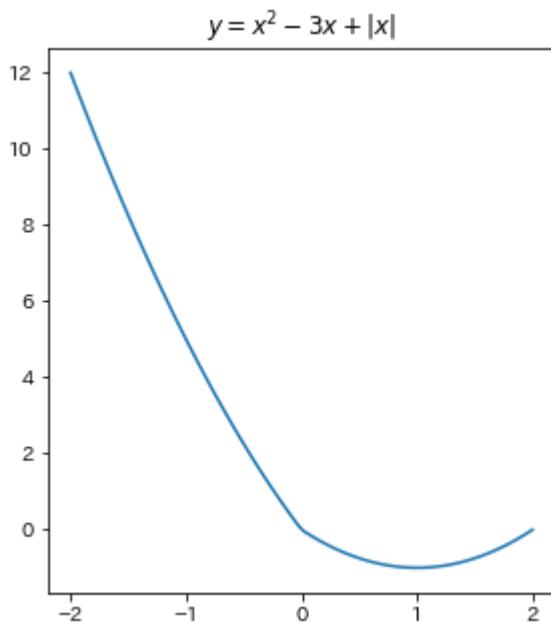
```
In [3]: x = np.linspace(-2,2,100)

def f1(x):
    return x**2 - 3*x + np.abs(x)

def f2(x):
    return x**2 + x + np.abs(x)

fig, ax = plt.subplots(1,2, figsize = (10,5))
ax[0].plot(x,f1(x))
ax[0].set_title('$y = x^2 - 3x + |x|$')
ax[1].plot(x,f2(x))
ax[1].set_title('$y = x^2 + x + 2|x|$')
```

```
Out[3]: Text(0.5, 1.0, '$y = x^2 + x + 2|x|$')
```

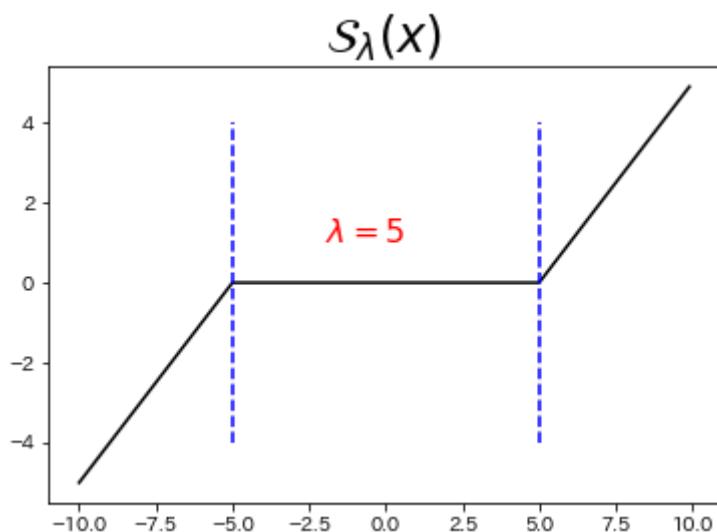


問題7

```
In [4]: def soft_th(lam, x):
    return np.sign(x)*(np.maximum(np.abs(x)-lam, np.zeros_like(x)))

x = np.arange(-10, 10, 0.1)
y = soft_th(5, x)
plt.plot(x, y, c="black")
plt.title(r"\$S_\lambda(x)\$", size=24)
plt.plot([-5, -5], [-4, 4], c="blue", linestyle="dashed")
plt.plot([5, 5], [-4, 4], c="blue", linestyle="dashed")
plt.text(-2, 1, r"\$\lambda=5\$", c="red", size=16)
```

Out[4]: Text(-2, 1, '\$\lambda=5\$')



問題8

```
In [5]: def linear_lasso(X, y, lam=0, beta=None): #座標降下法によるlasso
    n, p = X.shape #デザイン行列のサイズ
    if beta is None:
        beta = np.zeros(p) #学習により求める重み
```

```

X, y, X_bar, X_sd, y_bar = centralize(X, y) # 中心化
eps = 1
beta_old = copy.copy(beta) #同じポインタを参照しないための工夫
while eps > 0.00001: # このループの収束を待つ
    for j in range(p):
        r = y # (1)
        for k in range(p):
            if j != k:
                r = r - X[:, k] * beta[k]
        z = (np.dot(r, X[:, j]) / n) / (np.dot(X[:, j], X[:, j]) / n)
        beta[j] = soft_th(lam, z)
    eps = np.linalg.norm(beta - beta_old, 2) #更新前後での2ノルムの値で収束判定
    beta_old = copy.copy(beta)
beta = beta / X_sd # 各変数の係数を正規化前のものに戻す
beta_0 = y_bar - np.dot(X_bar, beta) #(2)
return beta, beta_0

def centralize(X0, y0, standardize=True): #中心化
    X = copy.copy(X0)
    y = copy.copy(y0)
    n, p = X.shape
    X_bar = np.zeros(p) # Xの各列の平均
    X_sd = np.zeros(p) # Xの各列の標準偏差
    for j in range(p):
        X_bar[j] = np.mean(X[:, j])
        X[:, j] = X[:, j] - X_bar[j] # Xの各列の中心化
        X_sd[j] = np.std(X[:, j])
        if standardize is True:
            X[:, j] = X[:, j] / X_sd[j] # Xの各列の標準化
    if np.ndim(y) == 2:
        K = y.shape[1]
        y_bar = np.zeros(K) # yの平均
        for k in range(K):
            y_bar[k] = np.mean(y[:, k])
            y[:, k] = y[:, k] - y_bar[k] # yの中心化
    else: # yがベクトルの場合
        y_bar = np.mean(y)
        y = y - y_bar
    return X, y, X_bar, X_sd, y_bar

df = np.loadtxt("../data/crime.txt")
X = df[:, 2:]
y = df[:, 0]
p = X.shape[1]
y = df[:, 0]
lambda_seq = np.arange(0, 200, 0.1) #0 ~ 199.9の200個生成
plt.xlim(0, 200)
plt.ylim(-10, 20)
plt.xlabel(r"\lambda")
plt.ylabel(r"\beta")
plt.title(r"各$\lambda$についての各係数の値")
labels = ["警察への年間資金", "25歳以上で高校を卒業した人の割合",
          "16-19歳で高校に通っていない人の割合",
          "18-24歳で大学生の割合", "25歳以上で4年制大学を卒業した人の割合"]
r = len(lambda_seq)
coef_seq = np.zeros((r, p))
for i in range(r):
    coef_seq[i, :] = linear_lasso(X, y, lambda_seq[i])
for j in range(p):
    plt.plot(lambda_seq, coef_seq[:, j], label=labels[j])
plt.legend(loc="upper right")

print("lambda = 10の時の係数", coef_seq[100, :])

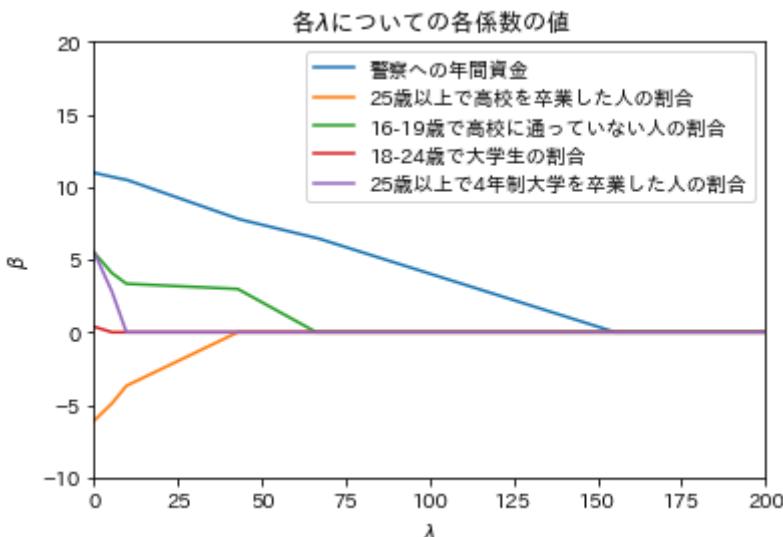
```

```

print("lambda = 50の時の係数",coef_seq[500,:])
print("lambda = 100の時の係数",coef_seq[1000,:])

lambda = 10の時の係数 [10.47248183 -3.64521939  3.33650908  0.         0.         ]
lambda = 50の時の係数 [ 7.40608466 -0.         2.0596716  -0.         -0.         ]
lambda = 100の時の係数 [ 4.03117071 -0.         0.         -0.         -0.         ]

```



結果より

$\lambda = 10$ の時は4,5番目の特徴量が0

$\lambda = 50$ の時は2番目の特徴量も0

$\lambda = 50$ の時は1番目の特徴量以外は全て0となる

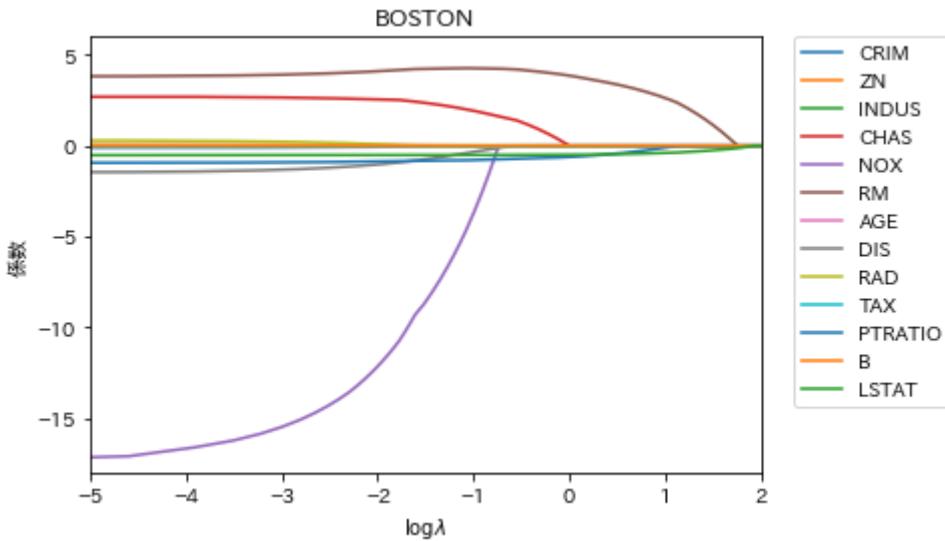
問題8

```

In [6]: #Boston datasetの読み込み
from sklearn.datasets import load_boston
boston = load_boston()
x = boston.data
y = boston.target
n, p = x.shape
lambda_seq = np.arange(0.0001, 20, 0.01)
r = len(lambda_seq)
plt.xlim(-5, 2)
plt.ylim(-18, 6)
plt.xlabel(r"$\log \lambda$")
plt.ylabel("係数")
plt.title("BOSTON")
labels = boston.feature_names
coef_seq = np.zeros((r, p))
for i in range(r):
    coef_seq[i, :], _ = linear_lasso(x, y, lam=lambda_seq[i])
for j in range(p):
    plt.plot(np.log(lambda_seq), coef_seq[:, j], label=labels[j])
plt.legend(bbox_to_anchor=(1.05, 1), loc='upper left', borderaxespad=0, fontsize=10)

```

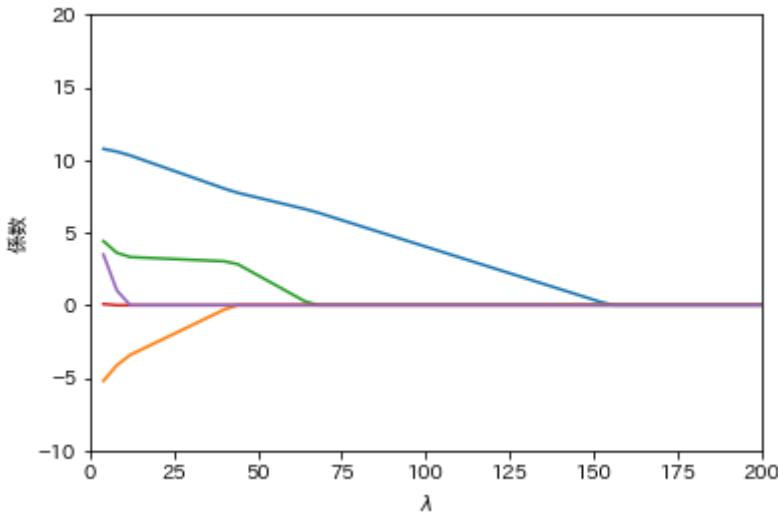
Out[6]: <matplotlib.legend.Legend at 0x7fd55f238ac0>



問題10

```
In [7]: def warm_start(X, y, lambda_max=100):
    dec = np.round(lambda_max / 50) #降り幅 1~maxを50等分する
    lambda_seq = np.arange(lambda_max, 1, -dec)
    r = len(lambda_seq)
    p = X.shape[1]
    beta = np.zeros(p)
    coef_seq = np.zeros((r, p))
    for k in range(r):
        beta, _ = linear_lasso(X, y, lambda_seq[k], beta)
        coef_seq[k, :] = beta #k番目のlambdaの値における重み
    return coef_seq

df = np.loadtxt("../data/crime.txt", delimiter="\t")
X = df[:, [i for i in range(2, 7)]]
p = X.shape[1]
y = df[:, 0]
coef_seq = warm_start(X, y, 200) #返り値が各ラムダにおける重み配列
lambda_max = 200
dec = round(lambda_max / 50)
lambda_seq = np.arange(lambda_max, 1, -dec)
plt.ylim(np.min(coef_seq), np.max(coef_seq))
plt.xlabel(r"\lambda")
plt.ylabel("係数")
plt.xlim(0, 200)
plt.ylim(-10, 20)
for j in range(p):
    plt.plot(lambda_seq, coef_seq[:, j])
```



問題13

```
In [8]: def ridge(X, y, lam=0):
    n, p = X.shape
    X, y, X_bar, X_sd, y_bar = centralize(X, y)
    beta = np.dot(
        np.linalg.inv(np.dot(X.T, X) + n * lam * np.eye(p)),
        np.dot(X.T, y)
    )
    beta = beta / X_sd
    beta_0 = y_bar - np.dot(X_bar, beta)
    return beta, beta_0

df = np.loadtxt("../data/crime.txt", delimiter="\t")
X = df[:, [i for i in range(2, 7)]]
y = df[:, 0]
linear(X, y)
```

Out[8]: (array([10.98067026, -6.08852939, 5.4803042 , 0.37704431, 5.50047122]),
489.6485969690334)

In [9]: ridge(X, y)

Out[9]: (array([10.98067026, -6.08852939, 5.4803042 , 0.37704431, 5.50047122]),
717.96)

In [10]: ridge(X, y, 200)

Out[10]: (array([0.0563518 , -0.01976397, 0.07786309, -0.0171218 , -0.0070393]),
717.96)

問題14

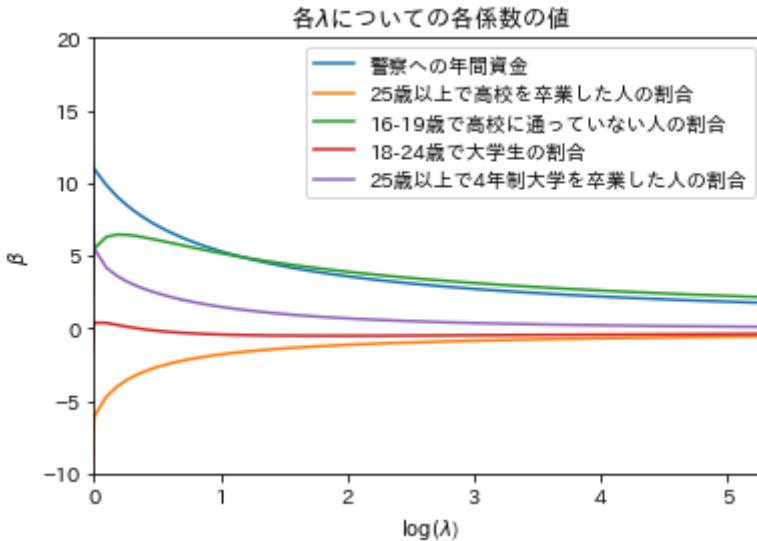
```
In [11]: df = np.loadtxt("../data/crime.txt", delimiter="\t")
X = df[:, [i for i in range(2, 7)]]
p = X.shape[1]
y = df[:, 0]
eps = 1e-10 #log(0)を防止するための微小項
lambda_seq = np.log(np.arange(0, 200, 0.1) + eps)
plt.xlim(0, np.log(200))
plt.ylim(-10, 20)
plt.xlabel(r"\$\\log(\\lambda\$)" ) #横軸の表示を変更
plt.ylabel(r"\$\\beta\$")
```

```

plt.title(r"各$\lambda$についての各係数の値")
labels = ["警察への年間資金", "25歳以上で高校を卒業した人の割合",
          "16-19歳で高校に通っていない人の割合",
          "18-24歳で大学生の割合", "25歳以上で4年制大学を卒業した人の割合"]
r = len(lambda_seq)
beta = np.zeros(p)
coef_seq = np.zeros((r, p))
for i in range(r):
    beta, beta_0 = ridge(X, y, lambda_seq[i])
    coef_seq[i, :] = beta
for j in range(p):
    plt.plot(lambda_seq, coef_seq[:, j], label=labels[j])
plt.legend(loc="upper right")

```

Out[11]: <matplotlib.legend.Legend at 0x7fd55f9640a0>



問題17

$z_1, z_2 \sim \mathcal{N}(0, 1)$
 x_1, x_2, x_3 は z_1 にノイズが乗っている
 x_4, x_5, x_6 は z_2 にノイズが乗っている

```

In [12]: np.random.seed(42)
n = 500
x = np.zeros((n, 6)) #特徴量次元 = 6
z = np.zeros((n, 2)) #これは2で十分
for k in range(2):
    z[:, k] = np.random.randn(n)
y = 3 * z[:, 0] - 1.5 * z[:, 1] + 2 * np.random.randn(n) #(1)
for j in range(3):
    x[:, j] = z[:, 0] + np.random.randn(n) / 5
for j in range(3, 6):
    x[:, j] = z[:, 1] + np.random.randn(n) / 5
lambda_seq = np.arange(0.1, 20, 0.1)
p = 6
r = len(lambda_seq)
coef_seq = np.zeros((r, p))
cols = ["blue", "red", "green", "yellow", "purple", "orange"]
for i in range(r):
    coef_seq[i, :], _ = linear_lasso(x, y, lambda_seq[i]) #(2)
for j in range(p):
    plt.plot(-np.log(lambda_seq), coef_seq[:, j] + 0.01 * j,
             c=cols[j], label="X"+str(j+1))
plt.xlabel(r"$-\log \lambda$")

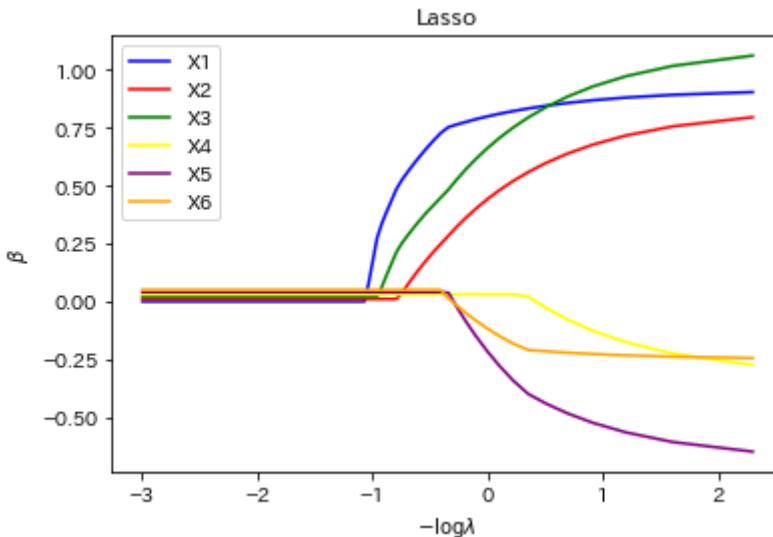
```

```

plt.ylabel(r"\beta")
plt.legend(loc="upper left")
plt.title("Lasso")

```

Out[12]: Text(0.5, 1.0, 'Lasso')



問題18

```

In [13]: def linear_lasso_kai(X, y, lam=0, beta=None, alpha = 1): #問題8のlinear_lassoの改良版
    n, p = X.shape #デザイン行列のサイズ
    if beta is None:
        beta = np.zeros(p) #学習により求める重み
    X, y, X_bar, X_sd, y_bar = centralize(X, y) # 中心化
    eps = 1
    beta_old = copy.copy(beta) #同じポインタを参照しないための工夫
    while eps > 0.00001: #このループの収束を待つ
        for j in range(p):
            r = y #(1)
            for k in range(p):
                if j != k:
                    r = r - X[:, k] * beta[k]
            z = (np.dot(r, X[:, j]) / n) / ((np.dot(X[:, j], X[:, j]) / n) + lam*(1-alpha)/np.sqrt((y-y_bar))
            beta[j] = soft_th(alpha*lam, z)
        eps = np.linalg.norm(beta - beta_old, 2) #更新前後での2ノルムの値で収束判定
        beta_old = copy.copy(beta)
    beta = beta / X_sd # 各変数の係数を正規化前のものに戻す
    beta_0 = y_bar - np.dot(X_bar, beta) #(2)
    return beta, beta_0

```

$\alpha = 1$ の時に問題17と同じ挙動を示すかテストする

```

In [14]: np.random.seed(42)
n = 500
x = np.zeros((n, 6)) #特徴量次元 = 6
z = np.zeros((n, 2)) #これは2で十分
for k in range(2):
    z[:, k] = np.random.randn(n)
y = 3 * z[:, 0] - 1.5 * z[:, 1] + 2 * np.random.randn(n) #(1)
for j in range(3):
    x[:, j] = z[:, 0] + np.random.randn(n) / 5
for j in range(3, 6):
    x[:, j] = z[:, 1] + np.random.randn(n) / 5
lambda_seq = np.arange(0.1, 20, 0.1)
p = 6
r = len(lambda_seq)

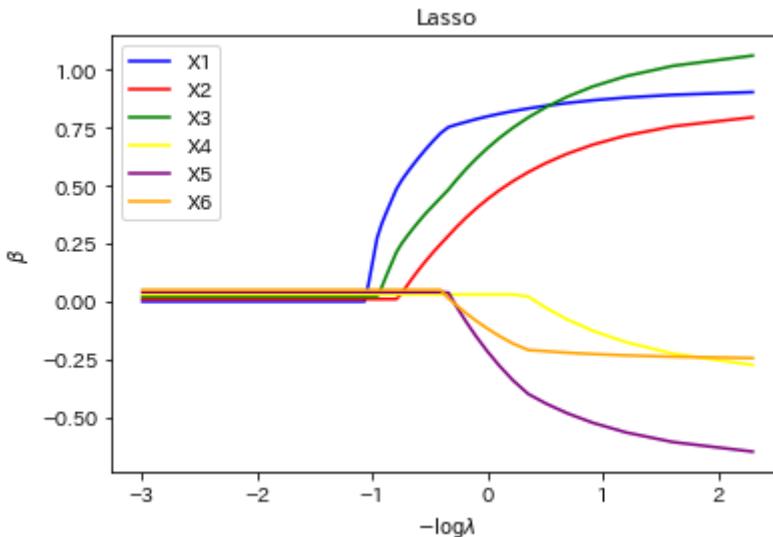
```

```

coef_seq = np.zeros((r, p))
cols = ["blue", "red", "green", "yellow", "purple", "orange"]
for i in range(r):
    coef_seq[i, :] , _ = linear_lasso_kai(x, y, lambda_seq[i], alpha = 1) #(2)
for j in range(p):
    plt.plot(-np.log(lambda_seq), coef_seq[:, j] + 0.01 * j,
             c=cols[j], label="X"+str(j+1))
plt.xlabel(r"$-\log \lambda$")
plt.ylabel(r"$\beta$")
plt.legend(loc="upper left")
plt.title("Lasso")

```

Out[14]: Text(0.5, 1.0, 'Lasso')



問題19

```

In [15]: def elastic_net(X, y, lam=0, alpha=1, beta=None): # 
    n, p = X.shape
    if beta is None:
        beta = np.zeros(p)
    X, y, X_bar, X_sd, y_bar = centralize(X, y) # 中心化
    eps = 1
    beta_old = copy.copy(beta)
    while eps > 0.00001: # このループの収束を待つ
        for j in range(p):
            r = y
            for k in range(p):
                if j != k:
                    r = r - X[:, k] * beta[k]
            z = (np.dot(r, X[:, j]) / n)
            beta[j] = (soft_th(lam * alpha, z) ## 
                       / (np.dot(X[:, j], X[:, j]) / n + (1-alpha) * lam)) ## elastic_netでの変更点
            eps = np.linalg.norm(beta - beta_old, 2)
            beta_old = copy.copy(beta)
        beta = beta / X_sd # 各変数の係数を正規化前のものに戻す
        beta_0 = y_bar - np.dot(X_bar, beta)
    return beta, beta_0

```

$\alpha = 1$ (lasso回帰)として問題17と同じ挙動を示すかテスト

```

In [16]: np.random.seed(42)
n = 500
x = np.zeros((n, 6)) # 特徴量次元 = 6
z = np.zeros((n, 2)) # これは2で十分
for k in range(2):

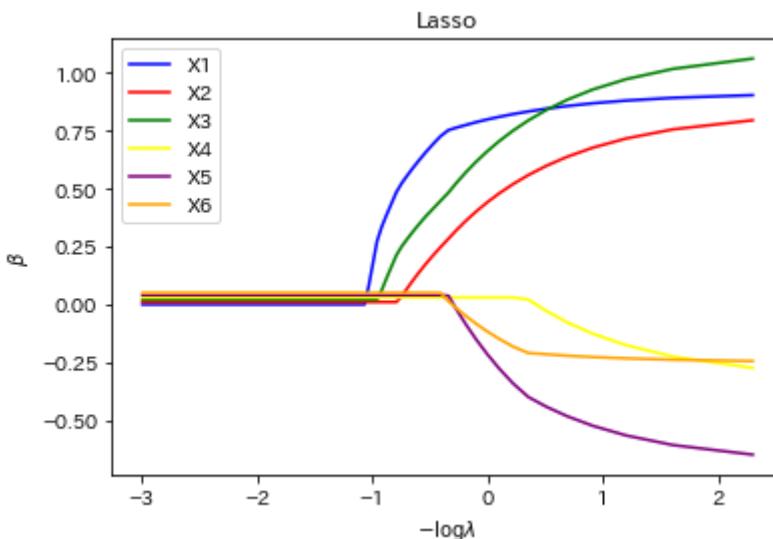
```

```

z[:, k] = np.random.randn(n)
y = 3 * z[:, 0] - 1.5 * z[:, 1] + 2 * np.random.randn(n) #(1)
for j in range(3):
    x[:, j] = z[:, 0] + np.random.randn(n) / 5
for j in range(3, 6):
    x[:, j] = z[:, 1] + np.random.randn(n) / 5
lambda_seq = np.arange(0.1, 20, 0.1)
p = 6
r = len(lambda_seq)
coef_seq = np.zeros((r, p))
cols = ["blue", "red", "green", "yellow", "purple", "orange"]
for i in range(r):
    coef_seq[i, :] = elastic_net(x, y, lambda_seq[i], alpha = 1) #(2)
for j in range(p):
    plt.plot(-np.log(lambda_seq), coef_seq[:, j] + 0.01 * j,
             c=cols[j], label="X"+str(j+1))
plt.xlabel(r"-log \lambda")
plt.ylabel(r"\beta")
plt.legend(loc="upper left")
plt.title("Lasso")

```

Out[16]: Text(0.5, 1.0, 'Lasso')



問題20

```

In [17]: def cv_linear_lasso(x, y, alpha=1, k=10, retall = False): # k-fold
    print(np.dot(x.T,x).shape)
    lam_max = np.max(np.dot(x.T, y) / np.dot(x.T, x)) #最初の非ゼロが現れるlambdaから始める
    lam_seq = np.arange(0, 1, 0.01)*lam_max
    n = len(y)
    m = int(n/k) #一つのバッチサイズ
    r = n%k
    S_min = np.inf
    obj_his = [] #目的関数の更新履歴

    for lam in lam_seq:
        S = 0 #暫定損失関数
        for i in range(k):
            index = range(i*m, i*m + m) #validation用のデータindex
            _index = list(set(range(n)) - set(index)) #学習用のデータindex
            beta, beta0 = elastic_net(x[_index], y[_index], lam, alpha)
            z = np.linalg.norm((y[index] - beta0 - np.dot(x[index], beta)), 2)
            S = S + z
        obj_his.append(S)
        if S_min > S:

```

```

S_min = S.copy()
lam_best = lam.copy()
beta0_best = beta0.copy()
beta_best = beta.copy()

if retall == True: #履歴を返す用
    return lam_best, beta0_best, beta_best, S_min, lam_seq, obj_his

return lam_best, beta0_best, beta_best, S_min

```

cross_validationのテスト

```

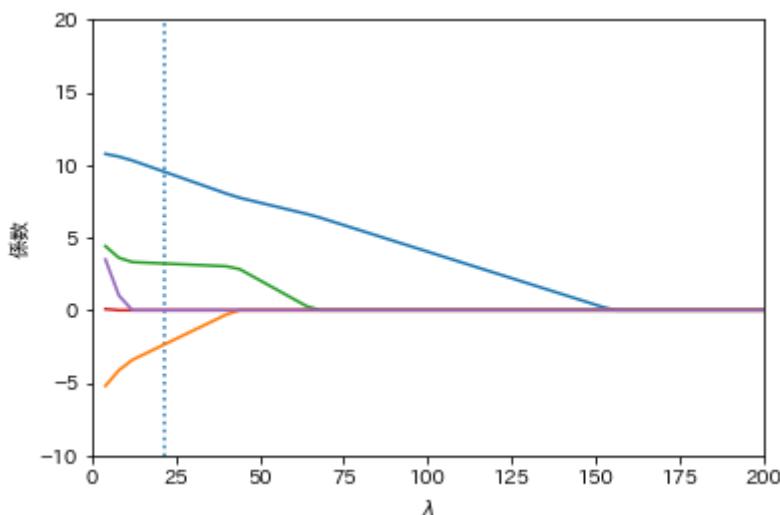
In [18]: df = np.loadtxt("../data/crime.txt", delimiter="\t")
X = df[:, [i for i in range(2, 7)]]
p = X.shape[1]
y = df[:, 0]
lam, beta0, beta, S = cv_linear_lasso(X, y)
print(lam)
print(beta0)
print(beta)
coef_seq = warm_start(X, y, 200)
lambda_max = 200
dec = round(lambda_max / 50)
lambda_seq = np.arange(lambda_max, 1, -dec)
plt.ylim(np.min(coef_seq), np.max(coef_seq))
plt.xlabel(r"$\lambda$")
plt.ylabel("係数")
plt.xlim(0, 200)
plt.ylim(-10, 20)
plt.axvline(x=lam, ymin=-10, ymax=10, linestyle="dotted")
for j in range(p):
    plt.plot(lambda_seq, coef_seq[:, j])

```

```

(5, 5)
21.797349629779895
527.046543093802
[ 9.51570956 -3.81437924  2.65954288 -0.         0.         ]

```



```

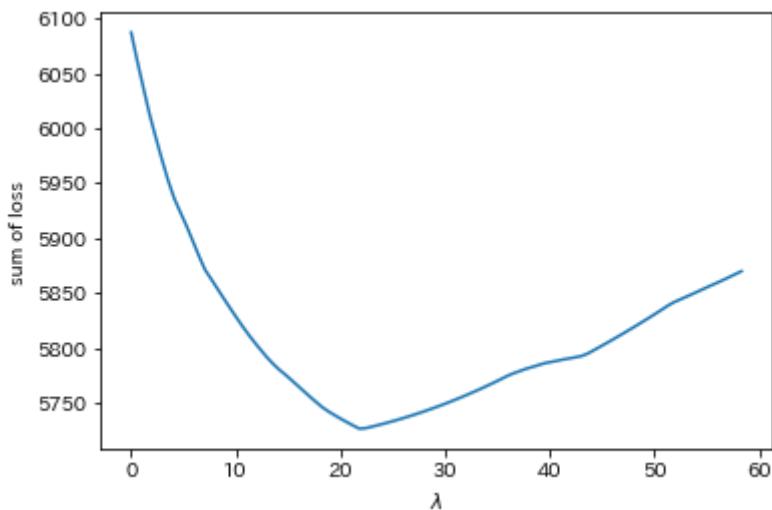
In [19]: df = np.loadtxt("../data/crime.txt", delimiter="\t")
X = df[:, [i for i in range(2, 7)]]
p = X.shape[1]
y = df[:, 0]
lam, beta0, beta, S, lam_seq, objval = cv_linear_lasso(X, y, retall = True)
coef_seq = warm_start(X, y, 200)
lambda_max = 200
dec = round(lambda_max / 50)

```

```
plt.plot(lam_seq, objval)
plt.xlabel(r"\lambda")
plt.ylabel("sum of loss")
```

(5, 5)

Out[19]: Text(0, 0.5, 'sum of loss')



実際に $\lambda = 21$ くらいで最小値を取っていることが確認できる